

大模型训练中的通信方式

原始问题：详细讲解大模型训练中所有通信方式，重点拆开讲解，说明应用位置、时机以及能否和计算 overlap。

提问：2026/07/26 15:26 更新：2026/07/27 01:53 重要度：5/5

一句话结论

大模型训练中的通信只有两大类：集合通信(Collective)和点对点通信(P2P)。集合通信是“一群 GPU 一起参与”(AllReduce/AllGather/ReduceScatter/All-to-All/Broadcast)，由 NCCL 实现；点对点是“一张卡发给另一张卡”(Send/Recv)，主要用于流水线并行传激活。

判别口诀：哪种并行策略，决定用哪种通信。DP→AllReduce；FSDP→ReduceScatter+AllGather；TP→AllReduce/AllGather；PP→P2P；MoE→All-to-All。几乎所有通信都能且应与计算 overlap。

地基：通信走哪条物理链路

链路	典型单向带宽	用途
NVLink/NVSwitch(机内)	~450 GB/s (H100)	同机 8 卡, TP 命脉
PCIe(机内)	~64 GB/s (Gen5)	GPU-CPU、offload
IB/RoCE(跨机 RDMA)	~50 GB/s (400Gbps)	跨节点, PP/DP 通信
以太网	更低	一般不用于训练热路径

核心认知：同一次 AllReduce，走 NVLink 和走跨机 IB 慢几个数量级。“哪种并行放机内、哪种跨机”是布局的头等大事。

关键图：四大核心集合通信原语

四大核心原语（4 卡，左=输入，右=输出）

AllReduce — 求和后每卡都拿全（DDP 梯度同步）



ReduceScatter — 求和后按分片切，每卡只留一份（FSDP 梯度）



AllGather — 各卡分片拼成完整，每卡都拿全（FSDP 拼参数）



All-to-All — 转置式重分布（MoE 路由）



关键恒等式（务必记住）

AllReduce = ReduceScatter + AllGather（FSDP 拆开 DDP 的数学本质）

Reduce = 求和到一张卡；Gather = 收集到一张卡（原语的“单点”版）

AllReduce —— 数据并行命脉

语义：每张卡有一份等长数据（通常是梯度），逐元素求和，结果每张卡都得到一份完整的和。

用在哪：DDP 梯度同步。N 卡各自在不同 mini-batch 上算梯度，反向后 AllReduce 得全局平均梯度，各自更新出一致参数。

例子：训练 Llama 用 DDP 起 128 卡，每卡吃不同数据，每 step 反向后对全部梯度(7B fp16=14GB)做一次 AllReduce。

通信量：Ring AllReduce 每卡 $\approx 2M$ ，几乎与卡数 N 无关（能 scale 千卡的原因）。

能否 overlap：能，且是头等大事。反向逐层从后往前，某层梯度算完就能立刻 AllReduce，同时继续算前面层。PyTorch DDP 用 gradient bucketing 自动实现。

ReduceScatter + AllGather —— FSDP/ZeRO 两把刀

核心恒等式：AllReduce = ReduceScatter + AllGather，这是理解 FSDP 的钥匙。

ReduceScatter: 各卡数据求和后按分片切开, 每卡只留 $1/N$ 。

AllGather: 每卡持一个分片, 通信后每卡拿到拼接的完整数据。

用在哪: FSDP/ZeRO-3。前向/反向前用 AllGather 拼回分片参数; 反向算完梯度用 ReduceScatter 求和并切片, 每卡留 $1/N$ 。

为什么不用 AllReduce: AllReduce 后每卡都拿完整梯度仍冗余; ReduceScatter 让每卡只拿 $1/N$, 配合分片优化器状态, 显存降到 $1/N$ 。FSDP 就是把 DDP 的一次 AllReduce 拆成 ReduceScatter + 平时的 AllGather。

能否 overlap: 能, 靠 prefetch。算第 i 层时提前 AllGather 第 $i+1$ 层参数; forward_prefetch/backward_prefetch 控制。

All-to-All —— MoE 专属

语义: 最“拧巴”的一个。每张卡都持有要发给所有其他卡的不同数据块; 通信后每张卡收到来自所有其他卡发给自己的块。本质是跨卡的“矩阵转置式重分布”。

用在哪: MoE 的 Expert Parallel。不同专家在不同卡上, token 经 router 后要发往选中专家所在的卡 (dispatch 一次 All-to-All), 专家算完再送回 (combine 一次 All-to-All)。

例子: 训练 Mixtral、DeepSeek-MoE, 每个 MoE 层两次 All-to-All。专家跨机时走 IB, 极易成瓶颈。

能否 overlap: 能但更难。依赖 router 输出 (先知道每个 token 去哪), 依赖链紧。先进实现 (DualPipe/Tutel) 会把 dispatch 与其他专家/dense 计算重叠, 工程复杂度高于 AllReduce overlap。

P2P Send/Recv —— 流水线并行接力棒

语义: 点对点, rank i 把一块数据 Send 给 rank j , rank j Recv。只涉及两张卡。

用在哪: PP 的 stage 间传激活。模型按层切成若干 stage 放不同卡, 前向时 stage k 算完把激活 Send 给 stage $k+1$; 反向把梯度 Send 回 stage k 。

例子: 把 80 层切 8 个 stage, 每 stage 10 层, 激活沿流水线逐级 Send/Recv, 配合 micro-batch 做 1F1B 调度。

通信特点: 量相对小(只传激活), 但存在流水线气泡(bubble)——stage 间有依赖, 启动收尾阶段部分卡闲置。

能否 overlap：能，这正是流水线调度核心。1F1B 让不同 micro-batch 的前向反向在不同 stage 交错，用一个 micro-batch 的计算掩盖另一个的 P2P 传输，压缩气泡。

overlap 的统一判据

能 overlap 的充要条件：

发起通信 C 后，存在不依赖 C 结果的独立计算 X 可立刻做 → C 与 X 并行

反例（无法 overlap）：

下一步计算立刻要用这次通信的结果 → 只能干等（暴露在关键路径）

对照：

DDP AllReduce → 易（反向逐层有独立计算）

FSDP AllGather → 易（prefetch 下一层）

TP AllReduce → 难（下一步立刻要用，依赖紧 → 必须放 NVLink）

PP P2P → 靠 1F1B 调度

MoE All-to-All → 能但需精心编排

物理下界：单步时间 $\geq \max(\text{总计算}, \text{总通信})$

数值算例：感受通信量级

DDP 训练 7B 模型，fp16 梯度，64 卡：

梯度总量 $M = 7e9 \times 2 \text{ Byte} = 14 \text{ GB}$

Ring AllReduce 每卡通信量 $\approx 2M = 28 \text{ GB}$

跨机 IB 有效带宽 $\approx 40 \text{ GB/s}$ ：

$T_{\text{comm}} \approx 28 / 40 \approx 0.7 \text{ s}$

若单步计算 $T_{\text{comp}} \approx 1.0 \text{ s}$ ：

无 overlap： $1.0 + 0.7 = 1.7 \text{ s}$

完美 overlap： $\max(1.0, 0.7) = 1.0 \text{ s} \rightarrow$ 加速约 1.7x

结论：通信占计算的比例(70%)决定 overlap 收益上限。

五策略通信对照 + 布局原则

DDP : AllReduce | 每step一次(分bucket) | 能overlap(bucketing)

FSDP : AllGather+ReduceScatter | 每层多次 | 能overlap(prefetch)

TP : AllReduce/AllGather | 每层多次(极重) | 难overlap(在关键路径)

PP : P2P Send/Recv | 每micro-batch一次 | 能overlap(1F1B)

MoE(EP) : All-to-All | 每MoE层两次 | 能但复杂

布局原则：越重越频繁的通信放越快的链路。典型 3D 并行：

TP → 机内 8 卡走 NVLink（每层通信最重）

PP → 跨机（P2P 轻，IB 扛得住）

DP/FSDP → 最外层跨机（AllReduce/AllGather 频率较低）

常见误区

- 1) 误以为 AllReduce 通信量随卡数线性增长：错，Ring 每卡趋近 2M，几乎与 N 无关。
- 2) 误以为 FSDP 比 DDP 通信更省：反了，FSDP 约 1.5 倍，省的是显存不是通信。
- 3) 把 TP 放跨机：严重错误，TP 每层通信、依赖紧、难 overlap，必须锁 NVLink 域内(≤ 8 卡)。
- 4) 以为开了 overlap 就一定生效：若通信 kernel 与计算抢 SM，或忘用独立 stream/pinned memory，overlap 名存实亡，必须 profiler 验证。
- 5) All-to-All 当廉价操作：MoE 跨机 All-to-All 常是瓶颈，专家负载不均会拥塞。