

MoE 架构详解：从稀疏路由到 Expert Parallel

原始问题：详细讲解 MoE 架构

提问：2026/07/29 20:27 更新：2026/08/05 16:26 重要度：5/5

MoE 架构详解：从稀疏路由到 Expert Parallel

一句话结论

MoE (Mixture of Experts, 混合专家) 是在 Transformer 的 FFN 位置放置多个独立 MLP Experts, 再让一个可学习 Router 为每个 Token 只选择少数 Top-k Experts。

它的核心价值是：

总参数量由全部 E 个 Experts 决定
每 Token 计算量只由激活的 k 个 Experts 决定
且通常 $k \ll E$

因此 MoE 可以让模型拥有非常大的参数容量，而不让每个 Token 都执行全部参数。

但 MoE 不是“免费扩大模型”：

- 所有 Expert 参数仍要存储、优化和加载；
- Router 可能把大量 Token 挤到少数 Experts, 产生负载不均；
- Expert Parallel 需要两次 Token All-to-All；
- 每个 Expert 收到的 Token 数动态变化，容易形成小 GEMM 和 GPU 低利用率；
- 训练需要处理负载均衡、容量溢出、Token Drop 和 Router 稳定性；
- 推理解码阶段 Batch 小、Token 少，MoE 的通信和专家权重访问更难摊薄。

一句话记忆：

Dense 模型让所有 Token 使用同一组 FFN 参数；MoE 让不同 Token 动态选择不同 FFN 参数。它用“条件计算”换取“更大的参数容量”。

一、MoE 在 Transformer 中放在哪里

标准 Transformer Block 通常包含：

```
Input
→ Attention
→ Residual
→ Dense FFN / MLP
→ Residual
→ Output
```

MoE 通常不替换 Attention，而是把某些层的 Dense FFN 替换为 Sparse MoE FFN：

```
Input
→ Attention
→ Residual
→ Router + Experts + Dispatch/Combine
→ Residual
→ Output
```

Dense FFN 对所有 Token 使用同一套参数：

$$\text{FFN}(x) = W_2 \cdot \text{activation}(W_1 x)$$

MoE 对 Token x_t 先选择专家集合 S_t ：


$$\text{MoE}(x_t) = \sum_{e \in S_t} g_{\{t,e\}} \cdot \text{Expert}_e(x_t)$$

其中：


E	Expert 总数
k	每个 Token 激活的 Expert 数
S_t	Token t 选中的 Top-k Expert 集合
$g_{\{t,e\}}$	Token t 对 Expert e 的路由权重

Transformer block 中: Attention 不变, FFN 被稀疏专家层替换

Dense FFN



Sparse MoE FFN: E=8, Top-k=2



总参数可含 8 个专家, 但该 token 只执行 2 个专家: 参数容量与每 token 计算量解耦。

MoE 不是什么

- 不是 Ensemble: 不是把多个完整模型都跑一遍再投票;
- 不是 Data Parallel: 不同 Experts 是不同参数, 不是同一模型副本;
- 不是简单模型分片: Router 会按 Token 动态决定执行路径;
- 不是减少总参数显存: 总 Expert 参数可能远大于 Dense 模型;
- 不是所有层都必须 MoE: 常见架构会按固定频率插入 MoE 层, 其他层仍为 Dense。

二、统一例子: 全文共用的 Shape 与参数

为了让结构、公式和代码完全对应, 使用一个小型可手算例子:

```
Batch B = 2
Sequence S = 3
Token 数 T = B × S = 6
Hidden Size H = 8
Expert 总数 E = 4
Top-k = 2
每个 Expert 的中间维度 F_expert = 16
对照 Dense FFN 的中间维度 F_dense = 32
Dtype = float32 (代码示例)
```

输入 Hidden States:

```
X: [B, S, H] = [2, 3, 8]
Flatten 后: X_flat: [T, H] = [6, 8]
```

Router 权重:

```
W_r: [H, E] = [8, 4]
Router Logits: X_flat @ W_r = [6, 4]
```

每个 Token 选择 2 个 Experts:

```
Top-k Indices: [T, k] = [6, 2]
Top-k Weights: [T, k] = [6, 2]
```

总 Token-Expert Assignments:

```
A = T × k = 6 × 2 = 12
```

为什么设置 `F_dense=32`、`F_expert=16`?

简单两层 MLP 每 Token FLOP 近似与中间维度成正比。Top-2 会执行两个 `F=16` 的 Experts:

```
2 × 16 = 32
```

因此它与一个 `F_dense=32` 的 Dense FFN 具有接近的主 MLP 计算量，便于比较参数容量与激活计算。

三、Dense FFN 与 MoE 的参数量、激活参数和 FLOP

先使用最简单的两层 MLP，忽略 Bias:

```
Expert(x) = W2 · activation(W1x)
W1: [H, F]
W2: [F, H]
```

3.1 Dense FFN 参数量

```
P_dense = H×F_dense + F_dense×H
          = 2HF_dense
```

代入：

```
P_dense = 2 × 8 × 32  
         = 512 params
```

3.2 MoE 全部 Expert 参数量

单个 Expert：

```
P_one_expert = 2HF_expert  
              = 2 × 8 × 16  
              = 256 params
```

4 个 Experts：

```
P_all_experts = E × 2HF_expert  
              = 4 × 256  
              = 1024 params
```

Router：

```
P_router = H × E  
          = 8 × 4  
          = 32 params
```

MoE 总参数：

```
P_moe_total = 1024 + 32 = 1056 params
```

3.3 每 Token 激活的参数量

Top-2 每 Token 只执行两个 Experts：

```
P_active_experts_per_token  
= k × 2HF_expert  
= 2 × 256  
= 512 params
```

加上 Router 投影约 32 个参数参与计算：

```
P_active_per_token ≈ 544 params
```

因此这个例子中：

指标	Dense FFN	MoE FFN
总参数	512	1056
每 Token 主 MLP 激活参数	512	512
Router 参数	0	32
Expert 数	1	4
每 Token 激活 Experts	1	2

结论：主 MLP 计算近似不变，但总参数容量约扩大 2 倍。

如果保持每个 Expert 和 Dense FFN 同样宽，同时使用 Top-2，那么每 Token Expert 计算会约变成 Dense FFN 的 2 倍。MoE 是否“同计算量”取决于：

$k \times F_{\text{expert}}$ 是否接近 F_{dense}

不能只看 $k \ll E$ 就断言计算完全不变。

3.4 FLOP 估算

矩阵乘的 Multiply-Add 按 2 FLOP 计。两层简单 MLP 每 Token：

$\text{FLOP}_{\text{one_expert}} \approx 4\text{HF}_{\text{expert}}$

Top-k：

$\text{FLOP}_{\text{moe_experts_per_token}} \approx 4k\text{HF}_{\text{expert}}$

Router：

$\text{FLOP}_{\text{router_per_token}} \approx 2\text{HE}$

代入：

Expert FLOP $\approx 4 \times 2 \times 8 \times 16 = 1024 \text{ FLOP/token}$
Router FLOP $\approx 2 \times 8 \times 4 = 64 \text{ FLOP/token}$

Dense 对照：

$\text{FLOP}_{\text{dense}} \approx 4 \times 8 \times 32 = 1024 \text{ FLOP/token}$

因此：

主 Expert MLP FLOP $\approx$ Dense MLP FLOP
MoE 额外增加 Router、Permutation 和通信成本


现代 Transformer 常使用 SwiGLU/Gated MLP，包含 3 个线性投影，参数量和 FLOP 系数会从 **2HF/4HF** 变为大约 **3HF/6HF**；但“总参数按 E 增长、激活计算按 k 增长”的关系不变。

四、MoE Layer 的四个阶段

一个 MoE Layer 的完整 Forward 可拆成：

1. Route
2. Dispatch
3. Expert Compute
4. Combine

一个 MoE FFN 的完整前向：Route $\rightarrow$ Dispatch $\rightarrow$ Compute $\rightarrow$ Combine



动态路由使每个专家收到的 token 数不同：负载不均、容量溢出和小 GEMM 是 MoE 的核心系统难点。

4.1 Route：为每个 Token 选择 Experts

输入：

$x: [T, H]$

Router 是一个小型线性投影：

```
L = XW_r

X:   [T, H]
W_r: [H, E]
L:   [T, E]
```

将 Logits 转成 Scores。经典形式：

```
P = softmax(L, dim=-1)
```

然后选择 Top-k：

```
indices, weights = topk(P, k)
```

通常会对选中的 **k** 个权重重新归一化：

$$g_{\{t,e\}} = p_{\{t,e\}} \div \sum_{\{j \in S_t\}} p_{\{t,j\}}$$

于是：

$$\sum_{\{e \in S_t\}} g_{\{t,e\}} = 1$$

部分架构使用 Sigmoid Score、Group-Limited Routing、Expert Bias 或 Aux-Loss-Free Balancing；不能把所有 MoE 都等同于“全局 Softmax + Top-2”。

4.2 Dispatch：把 Token 发给目标 Experts

Router 产生的是 Token→Expert Assignment。Expert 计算要求同一个 Expert 的 Token 在内存中连续，因此先 Permute：

```
原顺序: t0, t1, t2, t3, t4, t5
按 Expert 分组后:
E0 的 tokens | E1 的 tokens | E2 的 tokens | E3 的 tokens
```

如果所有 Experts 在同一 GPU，只需本地重排。

如果 Experts 分布在不同 GPU，需要执行 Expert Parallel 通信：

```
Dispatch All-to-All
```

把每个 Token Assignment 发送给目标 Expert 所在的 Rank。

4.3 Expert Compute: 每个 Expert 执行 MLP

Expert **e** 收到:

```
X_e: [T_e, H]
```

其中 **T_e** 是动态的, 每个 Expert 不同。

执行:

```
Y_e = Expert_e(X_e)
```

由于 **T_e** 可能很小、差异很大, 如果逐 Expert 启动独立 GEMM, 会产生:

- 大量小 GEMM;
- Kernel Launch 开销;
- Tensor Core 利用率低;
- 最慢 Expert/Rank 决定整体延迟。

因此生产实现常使用 Grouped GEMM: 把多个不同 **T_e** 的 Expert GEMM 组织在一次或少量 Kernel 中执行。

补充一: Grouped GEMM 到底怎样执行

先给结论: **Grouped GEMM** 不是把所有 Expert 的权重拼成一个共享权重大矩阵, 也不是让不同 Expert 互相混算; 它是在一次或少量 GPU Kernel Launch 中, 调度一组彼此独立、M 维不同但通常 K/N 相同的矩阵乘法。每个 Expert 仍使用自己的权重, 输出也仍属于自己的 Token 段。

1. 每个 Expert 实际有哪两个 GEMM

以普通两层 Expert MLP 为例:

```
X_e      [T_e, H]
W1_e     [H, F]
A_e      [T_e, F] = activation(X_e × W1_e)
W2_e     [F, H]
Y_e      [T_e, H] = A_e × W2_e
```

如果是 SwiGLU, 第一层通常包含 Gate/Up 两个投影; 工程上可以把两个投影融合成一个更宽的 GEMM, 再执行逐元素 **SiLU(gate) × up**, 最后做 Down Projection。

这里最麻烦的是 **T_e** 动态变化。假设一张 GPU 上有 3 个本地 Experts:

```
T_0 = 2, T_1 = 5, T_2 = 1
H = 4, F = 8
```

```
GEMM 0: [2,4] × [4,8] → [2,8]
GEMM 1: [5,4] × [4,8] → [5,8]
GEMM 2: [1,4] × [4,8] → [1,8]
```

若逐 Expert 调用 3 次 GEMM，GPU 会看到 3 个很小的 M 维问题。每次都要付 Kernel Launch、参数装载、调度和尾块浪费，Tensor Core 很难吃满。

2. Grouped GEMM 前先做 Token Permutation

Router/Dispatcher 先把属于同一 Expert 的 Token 排到连续内存中：

```
原 assignment 顺序：
[t0→E1, t1→E0, t2→E1, t3→E2, t4→E1, t5→E0, ...]

按 expert_id 排序后：
[E0: t1,t5] [E1: t0,t2,t4,...] [E2: t3]

packed_X:      [Σ_e T_e, H]
expert_offsets: [0, T_0, T_0+T_1, T_0+T_1+T_2, ...]
```

`expert_offsets` 是前缀和。第 `e` 个 Expert 的输入视图为：

```
X_e = packed_X[expert_offsets[e] : expert_offsets[e+1], :]
```

因此不需要为每个 Expert 单独分配不规则 Tensor；一个大 Buffer 加一组 Offset 就能描述全部变长输入。

3. 一个 Grouped GEMM Kernel 内部如何调度

Kernel 启动前会准备每组 GEMM 的描述符：

```
group e:
  A_ptr = X_e 首地址
  B_ptr = W_e 首地址
  C_ptr = Y_e 首地址
  M_e   = T_e
  N     = F
  K     = H
  lda / ldb / ldc
```

Kernel 不把三组矩阵数学上合并，而是把每组 GEMM 再切成 Tensor Core Tile，例如 `[M_tile, N_tile, K_tile]`。全局 Tile Scheduler 维护“第几个 Tile 属于哪一个 Expert”的映射：

```
Expert e 的输出 tile 数
tiles_e = ceil(T_e/M_tile) × ceil(F/N_tile)

prefix_tiles[e+1] = prefix_tiles[e] + tiles_e
```

一个 CTA/Thread Block 取得全局 `tile_id` 后，通过 `prefix_tiles` 找到所属 Expert，再加载该 Expert 的 `A_ptr/B_ptr/C_ptr` 和 shape，在自己的输出 Tile 上执行 K 维累加。Persistent Kernel 还会让同一个 CTA 连续领取多个 Tile，进一步摊薄 Launch 和调度开销。

Grouped GEMM：一组独立 GEMM，共享一次调度入口



关键边界

它减少 launch、改善 tile 填充和权重调度；不消除不同 Expert 的独立权重，也不消除 Rank 间负载不均。

若 T_e 极小，总 tile 数仍不足；若少数 T_e 极大，尾部仍由热门 Expert 决定。

性能应同时看 grouped GEMM 时间、每 Expert M 分布、Tensor Core active、HBM 带宽与最慢 Rank 尾部。

4. 为什么它更快，以及它不能解决什么

Grouped GEMM 的主要收益：

- 将多次小 GEMM Launch 合并为一次或少量 Launch；
- 把多个 Expert 的 Tile 放入同一调度池，增加可并行 CTA 数；
- 统一处理指针、shape、epilogue，减少 Host/Device 调度开销；
- 对变长 T_e 不必 Pad 到统一 Capacity，减少无效 FLOP。

但它不能解决：

- Rank 0 总共收到 2000 Tokens、Rank 1 只收到 500 Tokens 的跨 Rank 不均衡；
- 热门 Expert 的 T_e 远大于其他 Expert，形成计算长尾；
- T_e 全都极小，总工作量仍不足以填满 GPU；
- Permute/Unpermute 占用 HBM 带宽；
- Grouped GEMM 与通信同时运行时争抢 SM、L2 和 HBM。

Backward 也有对应的 Grouped GEMM：用分组矩阵乘计算 dX_e 、 $dW1_e$ 、 $dW2_e$ 。因此训练优化不能只看 Forward Kernel。

4.4 Combine：返回原 Rank，恢复顺序并加权

Expert 输出先通过第二次通信返回 Token 原始 Rank：

然后 Unpermute 恢复原 Token 顺序，并按 Router 权重合并：

$$y_t = \sum_{e \in S_t} g_{\{t,e\}} \cdot \text{Expert}_e(x_t)$$

最终输出 Shape 恢复为：

$$Y: [T,H] \rightarrow [B,S,H]$$

五、手算一个完整 Top-2 Routing 例子

设 6 个 Token 对 4 个 Experts 的 Top-2 结果如下：

Token	Expert 1	Weight 1	Expert 2	Weight 2
t0	E0	0.65	E3	0.35
t1	E1	0.70	E0	0.30
t2	E2	0.60	E3	0.40
t3	E0	0.55	E2	0.45
t4	E3	0.80	E1	0.20
t5	E1	0.52	E2	0.48

每 Expert Token Assignment 数：

```
E0: t0, t1, t3 → 3
E1: t1, t4, t5 → 3
E2: t2, t3, t5 → 3
E3: t0, t2, t4 → 3
```

总 Assignment：

$$3 + 3 + 3 + 3 = 12 = T \times k$$

Token **t0** 输出：

$$y_0 = 0.65 \cdot \text{Expert}_0(x_0) + 0.35 \cdot \text{Expert}_3(x_0)$$

同一个 Token 被复制成两个 Expert Assignments，但最终仍合并回一个 **[H]** 输出。

这个例子完全均衡。真实 Router 很容易出现：

```
E0: 6 assignments
E1: 3
E2: 2
E3: 1
```

此时 E0 变成热点，其他 Experts 空闲。

六、Expert Capacity、Capacity Factor 与 Token Dropping

6.1 平均容量

总 Assignment 数：

```
A = T×k
```

均匀分给 **E** 个 Experts，每 Expert 平均收到：

```
A_avg = T×k ÷ E
```

容量通常定义为：

```
Capacity C
= ceil(T×k×CapacityFactor ÷ E)
```

Megatron Core 文档给出的同类公式以每 Rank Token 数为口径：

```
capacity
= num_tokens_per_rank × topk × capacity_factor ÷ num_experts
```

具体是全局还是局部 Token 口径、是否向上取整、容量发生在通信前还是后，要以框架实现为准。

统一例子：

```
T=6, k=2, E=4, CapacityFactor=1.0
C=ceil(6×2÷4)=3
```

均衡路由时每 Expert 正好 3 个 Assignments，不溢出。

若 E0 收到 6 个：

```
overflow = 6-3 = 3
```

6.2 Token Dropping

Capacity-Based MoE 会只保留容量内的 Token Assignments，超出的 Assignment 被 Drop，常按 Router Probability 优先保留高分项。

风险：

- 被 Drop 的 Expert 路径不执行；
- 若 Token 的所有路径都被 Drop，会造成信息损失；
- Capacity 太小会影响模型质量；
- Capacity 太大则增加 Padding、显存和通信。

6.3 Padding to Capacity

为了得到固定 GEMM Shape，可以把不足容量的 Expert 输入补齐到 **C**：

```
Expert 真实收到 1 个 Token  
Capacity = 3  
→ Padding 到 3
```

优点：

- Shape 固定；
- Kernel 更规则；
- CUDA Graph 更容易；
- 集合通信尺寸可预测。

缺点：

- 计算 Padding；
- 浪费显存与带宽；
- Capacity Factor 越大，浪费越明显。

6.4 Dropless MoE

Dropless 实现不丢 Token，也不强制全部 Padding 到统一容量。每个 Expert 处理真实动态 Token 数。

优点：保留所有路由信息。

代价：

- 动态 Shape；
- Expert Token 数高度不均；
- Grouped GEMM 和通信实现更复杂；
- CUDA Graph、内存规划和负载均衡更难。

七、为什么 Router 会塌缩：负载均衡问题

如果某个 Expert 在训练早期偶然更擅长一些 Token，Router 会给它更高分；它获得更多数据，更新更充分，于是进一步变强：

```
更高路由概率
→ 更多 Token
→ 更多梯度和训练机会
→ Expert 更强
→ 更高路由概率
```

这会形成正反馈，导致：

- 少数 Experts 过载；
- 其他 Experts 几乎没有训练数据；
- All-to-All Rank 不均衡；
- 最慢 Rank 拖住全组；
- 容量溢出和 Token Drop 增加；
- Expert Specialization 退化。

八、Load Balancing Auxiliary Loss

一种经典思路同时约束：

1. 每个 Expert 实际分到的 Assignment 比例；
2. Router 给每个 Expert 的平均概率质量。

定义：

```
f_e = Expert e 实际接收的 Assignment 数 ÷ (T×k)
p_e = (1/T) × Σ_t P_{t,e}
```

补充二： p_e 是怎样算出来的

先给结论： p_e 是一个 Batch 内，Router 在 Softmax 后分给 Expert e 的平均概率质量；它不是 Expert 的实际 Token 个数。 f_e 是离散硬路由后的实际负载， p_e 是可微的软倾向。

常见定义为：

```
P_{t,e} = softmax(router_logits_t)[e]
p_e = (1/T) × Σ_t P_{t,e}
```

这里通常使用 Top-k 截断之前、对全部 E 个 Experts 的 Softmax 概率。因此：

```
对每个 token t: Σ_e P_{t,e} = 1
对整个 batch: Σ_e p_e = 1
```

一个 4 Token、3 Expert 的简单例子

假设 Router Softmax 后的概率是：

Token	P(E0)	P(E1)	P(E2)	Top-1 选择
t0	0.70	0.20	0.10	E0
t1	0.60	0.30	0.10	E0
t2	0.20	0.70	0.10	E1
t3	0.10	0.60	0.30	E1

逐列求平均：

```
p_0 = (0.70 + 0.60 + 0.20 + 0.10) ÷ 4 = 0.40
p_1 = (0.20 + 0.30 + 0.70 + 0.60) ÷ 4 = 0.45
p_2 = (0.10 + 0.10 + 0.10 + 0.30) ÷ 4 = 0.15

检查: p_0 + p_1 + p_2 = 1.00
```

Top-1 硬选择结果是 $[E0, E0, E1, E1]$ ，所以：

```
f_0 = 2/4 = 0.50
f_1 = 2/4 = 0.50
f_2 = 0/4 = 0.00
```

这说明 f 与 p 的含义不同：E2 没有真正接到 Token，所以 $f_2=0$ ；但 Router 仍给过 E2 一些概率，所以 $p_2=0.15$ 。

代入常见辅助损失的归一化主体：

```
E × Σ_e f_e p_e
= 3 × (0.50×0.40 + 0.50×0.45 + 0×0.15)
= 3 × 0.425
= 1.275
```

完全均匀时该主体为 1；这里大于 1，表示实际负载与概率质量共同偏向 E0/E1。最终损失还要乘 α 。

为什么同时需要 f_e 和 p_e

- 只看 f_e ：它来自 Top-k/argmax，离散、几乎不可导，难以直接训练 Router。
- 只看 p_e ：概率看似均匀，不代表 Top-k 后的硬分配真的均匀。
- 二者相乘：把“实际拥挤程度”作为系数，惩罚 Router 继续给拥挤 Expert 分配概率质量。

在把硬计数 f_e 视为当前 Batch 的常量时， L_{aux} 对 p_e 的系数与 f_e 成正比：越拥挤的 Expert，继续增加其概率的代价越大。Softmax 的耦合梯度会把概率质量转向负载较低的 Experts。

Top-2 时怎样改

若每个 Token 选择 $k=2$ ，总 Assignment 数为 $T \times k$ ，所以常见硬负载定义是：

```
f_e = count(assignments to e) ÷ (T×k)
```

但不同论文/框架可能使用：Top-k 前概率、Top-k 后重新归一化权重、按 Sequence/Group 局部统计，或给每个 k 槽位分别算损失。阅读实现时必须确认统计轴和分母，不能只看变量名 p_e 。

一个常见形式：

```
L_aux = α × E × Σ_e f_e p_e
```

其中：

```
α Auxiliary Loss 系数
E Expert 数
```

若完全均匀：

```
f_e = 1/E
p_e = 1/E

E × Σ_e (1/E × 1/E)
= E × E × 1/E²
= 1
```

训练时通常把它加到主 Loss：

```
L_total = L_task + L_aux + L_z + ...
```

不同论文和框架对 Top-k、归一化和比例系数的具体定义可能不同，不能看到“Aux Loss”就假设公式完全一致。

Aux Loss 的副作用

Aux Loss 太小：负载不均控制不住。

Aux Loss 太大：Router 为了均匀而均匀，可能损害语义路由与 Expert Specialization。

所以负载均衡与专家专门化存在张力：

绝对均匀不一定是质量最优
严重不均一定是系统灾难

现代系统还会使用：

- Expert Bias 动态调节；
- Aux-Loss-Free Balancing；
- Group-Limited Routing；
- Node-Limited Routing；
- Sinkhorn/S-BASE 等方法。

九、Router Z-Loss 与数值稳定性

Router Logits 可能持续增大，使 Softmax 饱和、梯度和低精度训练不稳定。

常见 Router Z-Loss：

```
L_z = \lambda_z \times \text{mean}_t[(\log \sum_e \exp(\mathbf{l}_{\{t,e\}}))^2]
```

它鼓励 Logits 不要无界增大。

还可能使用：

- Router 使用 FP32 计算；
- Input Jitter/Noise；

- Router Weight 初始化控制；
- Logit Clipping；
- 更稳定的 Softmax/Fused Kernel。

Router 参数很少，但它决定每个 Token 走哪条计算路径，因此数值问题可能放大成整个系统的路由异常。

补充三：Router Logits、Softmax 饱和与 Z-Loss

1. “Logits 持续增大”要拆成两种情况

这句话需要精确理解：

1. 所有 **Logits** 一起加同一个常数： $\mathbf{l}_t \leftarrow \mathbf{l}_t + \mathbf{c}$ 。Softmax 完全不变，因为 Softmax 具有平移不变性。
2. **Logit** 之间的差值持续放大：例如 $[2, 1, 0] \rightarrow [20, 10, 0]$ 。Softmax 会越来越接近 One-hot，这才是通常说的“饱和”。

```
softmax(l + c) = softmax(l)
```

因此主任务 Loss 可能根本不在意共同偏移量 $\mathbf{c}$ ，Router Logits 的绝对值可以漂移；同时路由竞争又可能拉大专家之间的差值。两类现象都会让数值尺度变差，但只有第二类直接让概率饱和。

2. Softmax 饱和为什么让梯度变小

Softmax Jacobian 为：

```
 $\partial p_i / \partial l_j = p_i \times (\delta_{ij} - p_j)$ 
```

若某个 Expert 概率 $p_i \approx 1$ ：

```
 $p_i(1-p_i) \approx 0$ 
```

其他 Experts 的 $p_j \approx 0$ ，对应梯度也很小。于是 Router 很难把一个已经极度自信的错误选择拉回来。

数值例子：

```
logits = [2, 1, 0]
softmax ≈ [0.665, 0.245, 0.090]
最大项局部斜率 ≈ 0.665 × 0.335 = 0.223

logits = [20, 10, 0]
```

```
softmax ≈ [0.999955, 0.000045, 0.000000002]
最大项局部斜率 ≈ 0.000045
```

后者梯度约小了 5000 倍。Router 一旦早期偏向某个 Expert，就更容易形成“越选越强、越强越难纠正”的正反馈，最终出现 Expert Collapse 或负载长尾。

3. 为什么低精度训练更容易不稳定

Softmax 要计算 $\exp(\text{logit})$ 。朴素实现对大正数可能上溢、对大负数可能下溢。稳定实现会先减去最大值：

```
m = max_e l_e
logsumexp(l) = m + log(Σ_e exp(l_e - m))
```

这能避免大部分直接 Overflow，但不能消除所有问题：

- BF16/FP16 的有效尾数有限，小概率可能舍入到 0；
- 饱和后 Top-k 边界对微小舍入误差敏感，临界 Experts 的顺序可能翻转；
- Fused Softmax/Top-k/Noise/Mask 的中间值若使用低精度，误差会积累；
- Router 的微小数值差异会变成离散路径差异，进一步改变每个 Rank 的 Token 数和通信形状；
- 路由异常会被 All-to-All、Capacity、Token Drop 和尾延迟放大为系统问题。

这就是“Router 参数很少，但数值问题可能放大成整个系统异常”的含义。

4. Z-Loss 公式逐项解释

对 Token t ，定义：

```
z_t = logsumexp(l_t)
      = log(Σ_e exp(l_{t,e}))

L_z = λ_z × mean_t(z_t^2)
```

变量含义：

$l_{\{t,e\}}$	Token t 对 Expert e 的 Router Logit, 无量纲
z_t	该 Token 的 Log-Partition, 衡量全部 $\exp(\text{logit})$ 的总尺度
λ_z	Z-Loss 系数, 无量纲
T	本次统计的 Token 数

z_t 不是熵，也不是最大概率。它是 Softmax 分母的对数。对全部 Logits 加常数 c 时：

```
logsumexp(l_t + c) = logsumexp(l_t) + c
```

所以虽然 Softmax 概率不变，Z-Loss 却会变化。这正好约束了主路由目标看不见的“共同偏移自由度”。

5. 一个最能说明 Z-Loss 的例子

```
A: logits = [2,1,0]
softmax ≈ [0.665,0.245,0.090]
z = log(exp(2)+exp(1)+exp(0)) ≈ 2.408
z² ≈ 5.80

B: logits = [12,11,10] = A + 10
softmax 与 A 完全相同
z ≈ 12.408
z² ≈ 153.96
```

对主路由概率而言 A/B 等价；对数值尺度而言 B 明显更差。Z-Loss 会强烈惩罚 B，把共同偏移压回来。

再看差值放大的情况：

```
C: logits = [20,10,0]
softmax 几乎 One-hot
z ≈ 20.000
z² ≈ 400
```

C 同时具有很大的绝对尺度和饱和概率，也会受到很强惩罚。

6. Z-Loss 的梯度到底在做什么

若 Batch 有 T 个 Tokens：

```
 $\partial L_z / \partial l_{t,e}$ 
=  $(2\lambda_z / T) \times z_t \times \text{softmax}(l_t)_e$ 
```

因为：

```
 $\partial \log \text{sumexp}(l_t) / \partial l_{t,e} = \text{softmax}(l_t)_e$ 
```

含义是：

- 当 $z_t > 0$ 时，梯度下降会把 Logits 向下推，概率越大的 Expert 推得越多；
- 当 $z_t < 0$ 时，会把 Logits 向上推；
- 最终倾向让 $\log \text{sumexp}(l_t)$ 靠近 0，使 $\sum \exp(\text{logit})$ 的尺度靠近 1。

注意：若所有 Logits 都是 0，则 $z = \log(E) > 0$ ，因此 Z-Loss 会把它们整体推向负方向；这不会改变 Softmax 的均匀分布，只是在选择一个数值更温和的绝对标尺。

7. Z-Loss 能做什么，不能做什么

Z-Loss 主要控制 **Logit 的绝对尺度/Log-Partition**，不是负载均衡 Loss 的替代品。它不能单独保证：

- 每个 Expert 收到相同 Token 数；
- Router 保持足够熵；
- 不发生 Top-k 边界抖动；
- 所有低精度 Kernel 都数值稳定。

因此常配合：Router/Softmax 用 FP32、合理初始化、稳定 `logsumexp`、必要时 Logit Clipping、Input Jitter，以及单独的负载均衡策略。 `$\lambda_z$` 太大会过度限制 Router 表达能力，必须结合 `max|logit|`、`logsumexp`、Router Entropy、Aux/Z Loss 占比和训练质量一起调。

十、Expert Parallelism: Experts 如何分到多张 GPU

当 Expert 总参数无法或不应复制到每张 GPU 时，使用 Expert Parallel (EP)。

统一并行例子：

```
E = 8 Experts
EP = 4 GPUs
每 GPU Local Experts = E ÷ EP = 2
```

映射：

```
GPU 0: Experts 0,1
GPU 1: Experts 2,3
GPU 2: Experts 4,5
GPU 3: Experts 6,7
```

EP=4, E=8: 每张 GPU 持有 2 个专家



1. Dispatch All-to-All: 按目标 Expert Owner 重分布

2. Local expert compute

每张 GPU 收到所有来源路由给本地专家的 token; 按 expert 分段后执行 Sequential/Grouped GEMM。
每专家 token 数不同 → GEMM shape 动态、负载由最慢 Rank 决定。

3. Combine All-to-All: 结果返回 Token Origin Rank

Top-k=2 时每个 token 通常会产生 2 份 expert assignment; 通信的是隐藏状态及元数据, 不是全部专家参数。

一个 Rank 上的本地 Token 可能被 Router 选到任意 Expert。因此 Forward 需要:

```
本地 Tokens
→ Router
→ 按 Expert Owner 分组
→ Dispatch All-to-All
→ Local Expert Compute
→ Combine All-to-All
→ 恢复原 Token 顺序
```

10.1 第一次 All-to-All: Dispatch

每个 Rank 把 Token Hidden State 发送到目标 Expert 所在 Rank。

发送的是:

- Hidden State;
- 路由权重;
- Token/Expert 索引或恢复顺序所需元数据。

不是把全部 Expert 参数来回发送。

10.2 第二次 All-to-All: Combine

Expert 计算完成后, 结果返回 Token 原始 Rank, 再进行 Unpermute 与 Weighted Sum。

Backward 会沿相反的数据依赖执行对应的通信与梯度计算，因此训练通信量比 Forward-only 更大。

补充四：两次 All-to-All、Backward 与通信计算 Overlap

先给结论：**MoE 的两次 All-to-All 是 Token Assignment 的“去程”和 Expert 输出的“回程”。**
Forward 有 Dispatch + Combine 两次；Backward 沿数据依赖再执行两次对应通信，因此训练时每个 MoE Layer 通常是 4 次大 Payload 交换。 真正的 Overlap 优化不是简单把通信放到另一条 Stream，而是要拆出独立 Chunk、明确事件依赖，并控制通信 Kernel 与 GEMM 对 SM/HBM 的争用。

1. 第一次 All-to-All: Dispatch 的完整数据流

每个 Rank 初始拥有本地 Tokens：

```
X_local: [T_local, H]
```

Top-k 路由产生：

```
expert_id: [T_local, k]
gate_weight: [T_local, k]
assignments: A_local = T_local × k
```

Dispatcher 对每个 Assignment 计算：

```
dst_rank      = owner_rank(expert_id)
local_expert  = expert_id 在目标 Rank 内的编号
origin_token  = 原 Token 行号
slot          = Top-k 的第几个槽位
```

然后执行五步：

1. 统计发给每个 Peer 的 Assignment 数 `send_counts[peer]` ；
2. 对 Counts 做 Prefix Sum，得到每个 Peer 在 Send Buffer 中的区间；
3. Permute/Pack Hidden State，使发往同一 Peer 的数据连续；
4. 若是 Dropless/变长协议，交换 Split Sizes，使接收方知道 `recv_counts` ；
5. 执行 All-to-All/All-to-All-v，把 Hidden States 发到 Expert Owner Rank。

Payload 的主项是：

```
send_hidden: [A_local, H]
```


元数据是否一起发送取决于实现：`local_expert` 和恢复映射通常需要；`gate_weight` 可以随 Assignment 发送，也可以留在 Origin Rank，等结果返回后再加权。不能把某个框架的选择当成所有实现的固定规则。

目标 Rank 收到来自所有 Peers 的 Token 后，还要按 `local_expert` 再分段，形成：

```
X_0 [T_0,H], X_1 [T_1,H], ...
```

随后才进入 Grouped GEMM。

2. 第二次 All-to-All: Combine 的完整数据流

本地 Experts 计算得到：

```
Y_e: [T_e,H]  
packed_Y: [Σ_e T_e,H]
```

回程按 `origin_rank` 重新 Pack，然后执行第二次 All-to-All，把每个 Assignment 的 Expert 输出送回 Token 原始 Rank。

Origin Rank 收到后使用保存的逆映射：

1. `Unpermute`：恢复到 `(origin_token, topk_slot)`；
2. 乘 Router 权重 `g_{t,e}`；
3. 对同一 Token 的 k 个 Expert 输出做 `scatter_add/weighted_sum`。

```
y_t = Σ_{eES_t} g_{t,e} × Expert_e(x_t)
```

Top-2 时一个 Token 去程复制成 2 个 Assignments，回程也会收到 2 个 Expert 输出，最后再合并回 1 个 `[H]` 向量。

3. Backward 为什么还要两次通信

Forward 的依赖是：

```
Origin X  
→ Dispatch A2A  
→ Expert Forward  
→ Combine A2A  
→ Origin Y
```

Backward 反向传播：

```
dY at Origin  
→ 按 Top-k 权重拆成 Assignment Gradients  
→ A2A 发回 Expert Owner
```

→ Expert Backward, 得到 `dx_assignment` 与 `dW_expert`
→ A2A 把 `dx_assignment` 返回 Origin
→ 对同一 Token 的梯度累加, 并计算 Router Gradient

所以可把 Backward 两次通信理解为: 先反向穿过 Forward Combine, 再反向穿过 Forward Dispatch。Expert 参数梯度通常留在 Expert Owner 上; 若 Expert 参数还有数据并行副本, 则可能另外发生其 DP/FSDP 通信。

4. 一条可落地的 Chunk Pipeline

假设把 Assignment 切成 `C0`、`C1` 两个 Chunk, 并至少有三条执行流:


`permute_stream` 负责 Pack/Unpack
`comm_stream` 负责 Dispatch/Combine
`compute_stream` 负责 Grouped GEMM

理想时序:

```
时间 →  
comm:    Dispatch C0 | Dispatch C1 | Combine C0 | Combine C1  
compute: | GEMM C0-----| GEMM C1-----|  
permute: Pack C0 | Pack C1      | Unpack C0      | Unpack C1
```

更准确地说, `GEMM C0` 必须等待 `Dispatch C0` 的接收完成; `Combine C0` 必须等待 `GEMM C0` 完成。不同 Chunk 之间若 Buffer 和映射独立, 就可以并行。

Chunked MoE pipeline: 依赖在 Chunk 内, 重叠发生在 Chunk 间



事件依赖

`dispatch_done[C] → GEMM C`; `gemm_done[C] → combine C`; 不同 C 使用独立 Buffer, 避免覆盖。

Collective 调用顺序必须在所有 Rank 完全一致; 即使某 Chunk 为空, 也不能让部分 Rank 跳过。

时间线上相交不等于免费: NCCL 与 GEMM 可能争用 SM、L2、HBM 和互联注入带宽。

5. 一个两 Chunk 的时间算例

不切 Chunk 时：

```
Pack/Unpack = 2 ms
Dispatch    = 4 ms
GEMM        = 8 ms
Combine     = 4 ms
串行总时间  = 18 ms
```

切成 2 个 Chunk 后，由于 Launch 变多，每 Chunk 假设：

```
Dispatch = 2.3 ms
GEMM      = 4.2 ms
Combine   = 2.3 ms
```

三阶段流水线：

时间区间	通信流	计算流
0–2.3 ms	Dispatch C0	空闲
2.3–4.6 ms	Dispatch C1	GEMM C0 开始
4.6–6.5 ms	等待	GEMM C0 继续
6.5–8.8 ms	Combine C0	GEMM C1 开始
8.8–10.7 ms	等待	GEMM C1 继续
10.7–13.0 ms	Combine C1	完成

核心路径约为 13 ms，而不是 18 ms。但若重叠导致 GEMM 从 4.2 ms 膨胀到 5.5 ms、通信从 2.3 ms 膨胀到 3.0 ms，收益会明显缩水。这也是为什么不能只看 Trace 中有重叠色块，必须比较 Kernel Duration 与端到端 Step Time。

6. 三类最实用的 Overlap 机会

6.1 Routed Dispatch/Combine 与 Shared Expert MLP 重叠

Shared Expert 对所有 Tokens 计算，通常不依赖 Routed Dispatch 的结果：

```
路径 A: Route → Dispatch → Routed Experts → Combine
路径 B: Shared Expert MLP
```

因此 Shared Expert 是很好的“通信遮挡物”。前提是 Shared GEMM 不把全部 SM/HBM 吃满，否则 NCCL 进展会变慢。

6.2 Routed Path 内部做 Chunk Pipeline

把 Tokens/Assignments 切 Chunk, 让 `Dispatch(C1)` 与 `GEMM(C0)`、`Combine(C0)` 与 `GEMM(C1)` 重叠。难点是标准 Collective 往往要等整次接收完成；若要做到更细粒度的“收到某 Expert 的一段就算”，通常需要 All-to-All-v/P2P、专用 Dispatcher 或支持 Progressive Receive 的后端。

6.3 Backward 中通信与 Expert 梯度计算重叠

Backward 可按 Chunk/Expert 流水化：某个 Chunk 的 `dY` 一到 Expert Owner 就开始计算该 Chunk 的 Expert Backward，同时其他 Chunk 仍在通信。`dW` 聚合、`dX` 回程和其他独立梯度计算之间也可能形成重叠窗口。

7. Chunk Size 为什么是首要调参旋钮

通信时间可近似为：

$$T_{\text{comm}}(n) \approx \alpha + n \div \text{BW_effective}$$

α	一次通信/Kernel 的固定启动延迟，单位：秒
n	Payload 字节数，单位：Byte
BW_effective	有效带宽，单位：Byte/s

Chunk 太小：

- α 被重复支付；
- NCCL Kernel/网络包效率差；
- Grouped GEMM 的 M 更小，Tensor Core 利用率下降；
- Event、Pack、Prefix Sum 和 Kernel Launch 增多。

Chunk 太大：

- Pipeline 填充/排空时间长；
- 可重叠窗口减少；
- 最后一个 Chunk 形成暴露尾部；
- 热门 Expert/Rank 的长尾更明显。

所以最佳 Chunk 不是“越小越好”，而是同时满足：通信达到带宽区间、Grouped GEMM 有足够 M、又能形成至少 2-4 个有效流水段。

8. CUDA Stream/Event 的正确依赖

概念伪代码：

```
for c in chunks:
    with stream(permute_stream):
        pack[c] = permute(assignments[c])
        pack_done[c].record()

    comm_stream.wait_event(pack_done[c])
    with stream(comm_stream):
        recv[c] = all_to_all_async(pack[c])
        dispatch_done[c].record()

    compute_stream.wait_event(dispatch_done[c])
    with stream(compute_stream):
        expert_out[c] = grouped_gemm(recv[c])
        gemm_done[c].record()

    comm_stream.wait_event(gemm_done[c])
    with stream(comm_stream):
        returned[c] = all_to_all_async(expert_out[c])
        combine_done[c].record()

    permute_stream.wait_event(combine_done[c])
    with stream(permute_stream):
        output.add_(unpermute_and_weight(returned[c]))
```

生产实现还必须处理：

- Buffer 生命周期不能在异步操作完成前被复用；
- Stream-aware Allocator/ `record_stream`，避免缓存分配器提前回收；
- 所有 Ranks 的 Collective 调用顺序一致，否则可能 Hang；
- 变长 Split Size 必须两端一致；
- 避免隐式 Default Stream 同步、Host `wait()` 或调试 API 把流水线串行化；
- 多条通信 Stream 不代表网络能无限并发，可能反而增加拥塞。

9. 为什么“放到两条 Stream”仍可能没有收益

NCCL GPU 通信通常也要运行 Kernel，会占一部分 SM；Pack/Unpack、Grouped GEMM 和通信都可能访问 HBM/L2。因此存在四类资源冲突：

资源	冲突表现	常见手段
SM	NCCL CTA 与 GEMM CTA 互抢	调 NCCL channels/CTA、通信流优先级、限制计算占满程度
HBM/L2	Permute、GEMM、NCCL 同时搬数据	融合 Permute、减少中间 Buffer、低精度通信
网络	多 Chunk/多 Rail 注入拥塞	拓扑感知 EP Group、Node-Limited Routing、合理 Chunk
启动/调度	Chunk 太多导致 Kernel 碎片	Persistent/Fused Kernel、批量提交、CUDA Graph（形状允许时）

流优先级也不是越高越好：高优先级通信可能减少暴露通信尾部，却让 GEMM 被抢占/延迟；最终应优化 Critical Path，而不是单个通信 Timer。

10. 针对你的优化工作，建议这样测

至少同时采集：

1. raw_dispatch / raw_combine
在不重叠或隔离环境下的通信基线
2. exposed_dispatch / exposed_combine
真正阻塞依赖消费者的可见通信时间
3. grouped_gemm_duration_overlap / grouped_gemm_duration_solo
判断 overlap 是否让 GEMM 膨胀
4. per-rank send/rcv bytes、send_counts 矩阵
判断热点 Peer 和负载偏斜
5. tokens_per_expert、max/mean、P95/P99 T_e
判断尾部由哪一个 Expert/Rank 造成
6. SM active、Tensor Core active、HBM throughput、NVLink/IB throughput
判断争用资源
7. pipeline bubble 与最后一个 Chunk tail
判断填充/排空是否吞掉收益

可定义近似隐藏率：

```
hidden_fraction = 1 - exposed_comm ÷ raw_comm
```

但要注意：如果 overlap 时通信本身因争用从 4 ms 膨胀到 7 ms，只用旧的 `raw_comm=4 ms` 会误导。应同时报告“隐藏了多少等待”和“通信/计算各自膨胀了多少”。最终裁决指标始终是 MoE Layer Latency 或 Step Time。

11. 最容易踩的正确性与性能坑

- **Collective 顺序不一致**：某 Rank 因 Chunk 为空跳过一次 All-to-All，其他 Rank 没跳，直接 Hang。
- **过早开 Expert GEMM**：只收到部分 Peer 数据，却误以为该 Expert 的输入已完整。
- **逆映射错误**：Combine 后 Token/Top-k Slot 对不上，数值可能不报错但训练悄悄劣化。
- **异步 Buffer 被覆盖**：下一 Chunk 复用 Send/Recv Buffer，前一次通信尚未完成。
- **只测 NCCL Timer**：通信变短但 Permute、GEMM 或尾部变长，端到端没有收益。
- **只看平均 Tokens/Expert**：P99 热门 Expert 才决定同步点。
- **Chunk 过细**：通信和 GEMM 都从带宽/算力受限退化为 Launch-Latency 受限。

关键总结

1. Grouped GEMM 用一个 Tile Scheduler 调度多组独立变长 GEMM；它减少 Launch 和小 GEMM 碎片，但不消除负载长尾。

2. `p_e` 是 Router 全概率的 Batch 均值, `f_e` 是 Top-k 后硬 Assignment 比例; 二者结合才能既看真实拥挤又给 Router 可微梯度信号。
3. Softmax 对共同偏移不敏感、对差值放大却会饱和; Z-Loss 通过惩罚 `logsumexp(logits)`² 固定绝对数值尺度, 不能替代负载均衡。
4. MoE Forward 是 Dispatch 去程 + Combine 回程, Backward 再来两次; Overlap 的核心是 Chunk、异步执行、事件依赖和资源争用控制。
5. 优化时要同时报告暴露通信、通信/GEMM 膨胀、负载分布和端到端 Critical Path, 不能只看时间线上是否出现重叠。

可选自测

1. 若 `T=4, E=3`, 概率矩阵如补充二, 改成 Top-2 后应如何定义 `f_e` 的分母?
2. 为什么 `[2, 1, 0]` 与 `[12, 11, 10]` 的 Softmax 相同, 但 Z-Loss 差异巨大?
3. 若两个 Chunk 的通信与 GEMM 已在不同 Stream 重叠, 但 Step Time 反而变长, 你会优先检查哪三个资源或指标?

继续学习

1. 前置: CUDA Stream/Event 与 NCCL 异步语义 —— overlap 正确性的底层基础。
2. 同层对比: All-to-All-v、P2P Dispatcher 与 DeepEP 类后端 —— 不同动态通信执行方式的差异。
3. 下游应用: MoE Chunk Pipeline 性能建模与 Nsight Systems 定位 —— 把本节方法落到真实优化实验。

十一、All-to-All 通信量手算

设某 EP Rank 原始拥有:

```
T_local = 4096 Tokens
H = 4096
Dtype = BF16 = 2 Byte
k = 2
EP = 8
```

总 Token Assignments:

```
A_local = T_local × k
          = 4096 × 2
          = 8192
```

若路由均衡，目标 Expert 在本 Rank 的概率约为 $1/EP$ ，需要发往远端的比例约：

$$(EP-1)/EP = 7/8$$

一次 Dispatch 的远端 Hidden State 发送量近似：

```
Bytes_dispatch_send
≈ T_local × k × H × dtype_bytes × (EP-1)/EP

= 4096 × 2 × 4096 × 2 × 7/8
= 58,720,256 Byte
= 56 MiB
```

Combine 方向近似再发送一次：

```
Forward 两次 All-to-All 发送 Payload
≈ 56 MiB + 56 MiB
= 112 MiB / Rank / MoE Layer
```

这还没有包括：

- 元数据；
- 对齐/Padding；
- 接收流量；
- Backward 通信；
- 不均衡导致的额外等待；
- 网络协议与实际带宽折损。

因此 MoE 常出现：参数 FLOP 看起来很省，但 All-to-All 却成为 Step Time 的主要瓶颈。

十二、为什么 All-to-All 很难优化

AllReduce 中每个 Rank 的消息量和形状通常可预测；MoE All-to-All 的消息量由本批 Token 路由结果动态决定：

```
Rank 0 可能向 Rank 1 发很多 Token
Rank 2 可能几乎不向 Rank 1 发
下一批又完全不同
```

难点包括：

- 每个 Peer 消息尺寸不同；

- 网络热点随 Batch 变化；
- 最慢 Rank 决定全组完成时间；
- 跨节点带宽远低于机内 NVLink；
- Token Permutation/Unpermutation 也消耗 HBM 带宽；
- 通信和 Expert GEMM 可能同时争用 HBM；
- Top-k 越大，Assignments 与通信近似线性增加。

常见优化：

- 尽量把 EP Group 放在高速互联域；
- 使用优化 Dispatcher，如 All-to-All/Flex/DeepEP 类后端；
- Token Permutation Fusion；
- Dispatch/Combine 与 Shared Expert 或其他计算 Overlap；
- Node-Limited Routing，减少跨节点目的地；
- 低精度通信；
- 调整 EP、TP、DP、CP 的映射；
- Batch-Level Overlap。

十三、MoE 能否与计算 Overlap

可以，但比 DDP AllReduce Overlap 更复杂。

一个典型机会：

Routed Experts 路径: Route → Dispatch A2A → Expert Compute → Combine A2A
Shared Expert 路径: Shared Expert MLP

如果两条路径没有直接依赖，可以：

Dispatch All-to-All 与 Shared Expert Compute 重叠
Expert Compute 与其他通信阶段流水化
Combine 与后续可独立任务重叠

也可以把 Token 分 Chunk，形成：

Chunk 0 通信
→ Chunk 0 计算，同时 Chunk 1 通信

但实际 Overlap 受限于:

- NCCL/通信 Kernel 是否占 SM;
- Expert GEMM 和通信是否争抢 HBM;
- 消息是否足够大;
- Chunk 太小导致 Launch 开销;
- 路由结果是否提前可用;
- CUDA Stream/Event 依赖;
- 跨节点带宽与拓扑。

因此“时间线上重叠”不等于“通信完全隐藏”。要用 Nsight Systems 和框架 Timer 看:

```
exposed dispatch time
exposed combine time
expert GEMM utilization
per-expert token histogram
per-rank send/rcv bytes
```

十四、Expert Compute 为什么需要 Grouped GEMM

假设本地有 4 个 Experts, Token 数分别为:

```
T_0=128, T_1=64, T_2=19, T_3=173
```

若逐个执行:

```
GEMM Expert 0
GEMM Expert 1
GEMM Expert 2
GEMM Expert 3
```

问题:

- 4 次或更多 Kernel Launch;
- 小 $M=T_e$ GEMM 难以占满 GPU;
- 动态 Shape 多;
- Expert 2 只有 19 个 Token, 效率很低。

Grouped GEMM 把多个不同 **M**、相同或兼容 **K/N** 的 GEMM 组织起来：

一次 Grouped GEMM
处理多个 Expert 的 Token 分段和权重分段

收益：

- 减少 Launch；
- 更好地调度 Tensor Core 工作；
- 提升多个小 Expert 的整体利用率；
- 与 FP8/低精度 Expert Kernel 结合。

但 Grouped GEMM 不能消除负载不均：如果某个 Rank 收到远多于其他 Rank 的 Token，其他 Rank 仍要等待。

十五、Shared Experts 与 Routed Experts

传统 MoE 所有知识都由 Routed Experts 承担，可能产生：

- 不同 Experts 重复学习通用知识；
- Router 为常见模式浪费路由容量；
- Routed Expert Specialization 不够纯粹。

Shared Expert 对所有 Token 始终执行：

$$Y = \text{SharedExpert}(x) + \sum_{\{e \in S_t\}} g_{\{t,e\}} \text{RoutedExpert}_e(x)$$

作用：

- Shared Expert 学习通用知识；
- Routed Experts 更专注差异化知识；
- 减少 Routed Experts 之间的冗余；
- Shared 路径可作为通信 Overlap 的计算来源。

代价：

- Shared Expert 是 Dense Compute，所有 Token 都执行；
- 增加每 Token FLOP；

- 需要设计共享与路由输出如何融合；
- 可能再次成为计算瓶颈。

十六、Fine-Grained Expert Segmentation

DeepSeekMoE 提出的核心思想之一是把较大的 Experts 细分为更多、更小的 Experts。

传统：

N 个大 Experts, 激活 K 个

细粒度方案：

mN 个小 Experts, 激活 mK 个

若每个小 Expert 大约是原 Expert 的 $\frac{1}{m}$ 宽度，则激活总计算可保持接近，但组合方式更多：

C(N,K) 种粗粒度组合
→ C(mN, mK) 种更灵活的细粒度组合

目标：让专家知识分解得更细，Token 可以组合多个更专门的能力单元。

代价：

- Experts 更小，单个 GEMM 更碎；
- Router 输出维度更大；
- Assignment 数更多；
- Dispatch 元数据和通信更复杂；
- 更依赖 Grouped GEMM 和高效 Dispatcher。

因此 Fine-Grained Experts 是模型表达能力和系统效率的共同设计，而不是单纯增加 Expert 数。

十七、训练阶段与推理阶段有什么不同

17.1 训练

训练需要：

- Router 梯度；
- Expert 参数梯度；
- Load Balancing Aux Loss；
- Router Z-Loss；
- Forward 与 Backward All-to-All；
- Optimizer State；
- Expert 参数分片/复制；
- Activation 保存或重计算。

训练的 Token 数通常较大，Grouped GEMM 和通信更容易形成大批量，但 All-to-All 也很重。

17.2 Prefill 推理

Prompt Prefill 一次有较多 Token：

Batch × Prompt Length

Expert GEMM 相对较大，GPU 利用率通常比 Decode 好；但路由不均仍可能造成 Rank 热点。

17.3 Decode 推理

每条序列每步只产生一个新 Token。若 Batch 不大：

T 很小
→ 每 Expert 收到的 Token 更少
→ GEMM 极小
→ All-to-All 延迟难摊薄

同时所有 Expert 权重仍需驻留在 GPU 集群内，容易出现：

- Memory Capacity 压力；
- Expert Weight 访问不连续；
- 跨 GPU 通信主导 TPOT；
- 某些热门 Experts 形成尾延迟；

- Expert Cache/Offload 命中率问题。

所以“MoE 训练吞吐高”不代表“MoE 单请求推理延迟低”。

十八、MoE 与 Dense 模型的核心对比

维度	Dense Transformer	Sparse MoE Transformer
FFN 参数	每层一套	每层多个 Routed/Shared Experts
每 Token 执行路径	固定	Router 动态选择
总参数与计算关系	基本同步增长	总参数按 E 增长，激活计算按 k 增长
通信	TP/DP/PP 等	额外 Token Dispatch/Combine All-to-All
GEMM Shape	相对规则	每 Expert Token 数动态，易产生小 GEMM
负载均衡	主要是静态切分	Router 动态负载，需均衡策略
显存	参数与优化器状态可预测	Expert 总参数很大，分片与优化器更复杂
容错/调试	路径固定，较容易	动态路由、Token Drop、通信和质量耦合
推理解码	Batch GEMM 相对稳定	小 Batch 时 Expert GEMM 与 A2A 难摊薄
优势	简单、稳定、硬件友好	大参数容量、条件计算、潜在专家专门化

十九、MoE 与各种并行策略的关系

MoE 不是替代其他并行策略，而是增加一个新的并行维度：Expert Parallel。

DP: 复制模型/分片训练数据
TP: 切单个 Dense/Expert 内部矩阵
PP/VPP: 沿层深度切模型
CP: 切序列上下文
EP: 把不同 Experts 放到不同 Rank

常见组合：

TP × PP/VPP × DP/FSDP × EP × CP

关键拓扑原则：

- TP 每层频繁通信，优先放高速 NVLink 域；
- EP All-to-All 对跨节点网络非常敏感；
- EP 太小，每卡 Expert 参数多、显存压力高；
- EP 太大，All-to-All 范围大、每 Expert Token 少、GEMM 更碎；
- DP/FSDP 如何处理 Expert 参数，需要区分 Dense 参数组和 Expert 参数组；
- 某些框架要求 EP 与 TP 组合时启用 Sequence Parallel；
- Attention 与 MoE 的最优并行布局可能不同，因此出现 Parallel Folding 等解耦映射。

二十、最小 PyTorch MoE 实现

下面代码是单 GPU、Dropless、Top-2 的教学实现。它保留真实 Router、Top-k、按 Expert 分组计算和加权合并，但没有分布式 All-to-All、容量限制和高性能 Grouped GEMM。

```
import torch
import torch.nn as nn
import torch.nn.functional as F

class Expert(nn.Module):
    def __init__(self, hidden_size: int, ffn_size: int):
        super().__init__()
        self.w1 = nn.Linear(hidden_size, ffn_size, bias=False)
        self.w2 = nn.Linear(ffn_size, hidden_size, bias=False)

    def forward(self, x):
        # x: [tokens_for_this_expert, H]
        return self.w2(F.relu(self.w1(x)))

class SimpleTopKMoE(nn.Module):
    def __init__(
        self,
        hidden_size=8,
        ffn_size=16,
        num_experts=4,
        top_k=2,
    ):
        super().__init__()
        self.hidden_size = hidden_size
        self.num_experts = num_experts
        self.top_k = top_k

        self.router = nn.Linear(
            hidden_size,
            num_experts,
            bias=False,
        )

        self.experts = nn.ModuleList([
            Expert(hidden_size, ffn_size)
            for _ in range(num_experts)
        ])

    def forward(self, x):
```

```

# x: [B, S, H]
batch, seq, hidden = x.shape
flat = x.reshape(-1, hidden)      # [T, H]
tokens = flat.shape[0]

# 1. Route
logits = self.router(flat)        # [T, E]
probs = torch.softmax(logits, dim=-1)

top_weights, top_indices = torch.topk(
    probs,
    k=self.top_k,
    dim=-1,
)                                  # both [T, k]

# 只在选中的 k 个 Experts 内重新归一化。
top_weights = top_weights / top_weights.sum(
    dim=-1,
    keepdim=True,
)

# 2~4. Dispatch、Expert Compute、Combine
output = torch.zeros_like(flat)   # [T, H]
tokens_per_expert = []

for expert_id, expert in enumerate(self.experts):
    # selected: [T, k], 表示每个 Token 的每个 Top-k Slot
    # 是否选择了当前 Expert。
    selected = top_indices == expert_id

    # 找出所有选择当前 Expert 的 Token 和对应 Top-k Slot。
    token_idx, slot_idx = torch.where(selected)
    tokens_per_expert.append(token_idx.numel())

    if token_idx.numel() == 0:
        continue

    expert_input = flat[token_idx]   # [T_e, H]
    expert_output = expert(expert_input) # [T_e, H]

    gate = top_weights[token_idx, slot_idx] # [T_e]
    weighted = expert_output * gate.unsqueeze(-1)

    # 多个 Expert 对同一个 Token 的贡献累加。
    output.index_add_(0, token_idx, weighted)

output = output.reshape(batch, seq, hidden)

aux = {
    "router_logits": logits,
    "router_probs": probs,
    "top_indices": top_indices,
    "top_weights": top_weights,
    "tokens_per_expert": torch.tensor(
        tokens_per_expert,
        device=x.device,
    ),
}

return output, aux

torch.manual_seed(0)

model = SimpleTopKMoE(
    hidden_size=8,
    ffn_size=16,
    num_experts=4,
    top_k=2,
)

x = torch.randn(2, 3, 8) # [B=2, S=3, H=8]
y, aux = model(x)

```



```

print("input shape:", x.shape)
print("output shape:", y.shape)
print("top indices shape:", aux["top_indices"].shape)
print("top weights shape:", aux["top_weights"].shape)
print("tokens per expert:", aux["tokens_per_expert"].tolist())
print("assignments:", int(aux["tokens_per_expert"].sum()))

# 最小反向验证: Router 和被选 Experts 都能收到梯度。
loss = y.square().mean()
loss.backward()

print("router grad exists:", model.router.weight.grad is not None)

```

预期 Shape:

```

input shape: [2,3,8]
output shape: [2,3,8]
top indices shape: [6,2]
top weights shape: [6,2]
assignments: 12

```

这段代码说明了什么

- Router 对每个 Token 产生 `[E]` Scores;
- Top-k 产生 `[T,k]` Expert IDs 和 Weights;
- 同一个 Token 会被多个 Experts 处理;
- `index_add_` 把多个 Expert 的加权输出合并回原 Token;
- Router 的 Top-k Index 是离散选择, 但选中权重仍可对 Router 反向传播;
- 未被选中的 Expert 本批可能没有梯度。

它没有说明什么

生产实现还需要:

- Expert Capacity/Token Drop;
- EP All-to-All;
- 高性能 Permute/Unpermute;
- Grouped GEMM;
- Router Aux Loss/Z-Loss;
- Shared Experts;
- FP8/BF16;
- TP/DP/PP/CP 组合;
- 通信与计算 Overlap;

- 分布式 Checkpoint;
- 动态 Shape 与 CUDA Graph。

二十一、训练中应该监控哪些指标

Router/负载

```
Tokens per Expert Histogram
Max / Mean Tokens per Expert
Expert Utilization
Router Entropy
Top-k Probability
Aux Loss
Z-Loss
Drop Rate / Overflow Rate
```

负载不均衡比:

```
Imbalance Ratio = max_e(T_e) ÷ mean_e(T_e)
```

越接近 1 越均匀，但也不能只追求绝对均匀而牺牲语义路由。

通信

```
Dispatch All-to-All Time
Combine All-to-All Time
Exposed A2A Time
Per-Rank Send/Recv Bytes
Cross-Node Traffic
Permutation/Unpermutation Time
```

Expert Compute

```
Grouped GEMM Time
Per-Expert GEMM M Dimension
Tensor Core Utilization
Kernel Launch Count
Expert Compute Imbalance
```

端到端

```
Step Time
Tokens/s
MFU
```

Peak Memory
Optimizer Memory
Activation Memory
Checkpoint Time

不要只看“总 FLOP 少了多少”。MoE 的性能可能被通信、Permutation 和小 GEMM 完全主导。

二十二、常见失败模式

失败 1: Expert Collapse

少数 Experts 获得大部分 Token，其他 Experts 不训练。

排查：Tokens-per-Expert、Router Entropy、Aux Coeff、Input Distribution。

失败 2: Capacity 太小，Drop Rate 高

模型质量下降，部分 Token 路径丢失。

排查：Capacity Factor、Top-k、Router Skew、Drop Policy。

失败 3: Capacity 太大，Padding 浪费

固定 Shape 方便，但大量 Padding 吃掉计算和通信。

失败 4: EP Group 跨慢网络

All-to-All 暴露时间过高，训练吞吐下降。

失败 5: Experts 太细，Grouped GEMM 仍很小

模型表达更灵活，但 GPU Tensor Core 吃不满。

失败 6: Aux Loss 太强

路由很均匀，但专家无法形成有意义的专门化。

失败 7: 推理 Batch 太小

每 Expert 只有少量 Token，Decode TPOT 被通信和 Kernel Launch 主导。

失败 8：只优化通信，不看 HBM 与 Permutation

All-to-All 变快后，Permutation、Unpermutation 或 Expert GEMM 成为新瓶颈。

二十三、什么时候适合使用 MoE

适合：

- 希望在相近每 Token FLOP 下扩大参数容量；
- 训练 Token 规模足够大，能让 Experts 获得充足数据；
- 集群有高速互联，能承受 EP All-to-All；
- 有成熟的 Router、Grouped GEMM、Dispatcher 和并行框架；
- 目标是大规模预训练/高吞吐 Serving；
- 可以接受更高工程复杂度和参数显存。

不适合：

- 模型规模不大，Dense 已能满足容量需求；
- 单请求低延迟是绝对优先，Batch 很小；
- 跨节点网络差；
- 训练数据不足，Experts 难以专门化；
- 团队缺少路由、通信、Checkpoint 和可观测性能力；
- 显存只能容纳 Active 参数，却无法容纳/分片全部 Expert 参数。

二十四、常见误区

误区 1：MoE 只加载被选中的 Experts，所以总参数不占显存

错误。训练时全部 Expert 参数及其梯度/优化器状态必须存在于某些设备或存储层中；EP 只是把它们分散，不是让未选 Experts 消失。

误区 2: Top-2 表示同时运行两个完整模型

错误。通常只是同一 Transformer Block 的两个 Expert FFN，被选结果在该层加权合并。

误区 3: MoE 总参数增加 E 倍，计算一定不变

错误。每 Token 计算取决于 $k \times F_{\text{expert}}$ 、Router、Shared Experts、Padding、通信和实现开销。

误区 4: 负载越均匀，模型质量一定越好

错误。系统需要避免严重热点，但过强均衡可能损害专家专门化。

误区 5: All-to-All 是唯一瓶颈

错误。Permutation、动态小 GEMM、内存、Router、Checkpoint 和 Decode 小 Batch 都可能成为主要瓶颈。

误区 6: MoE 更省训练显存

不一定。Active FLOP 较少不代表总参数、梯度和优化器状态少；MoE 的参数显存常显著高于相近计算量的 Dense 模型。

二十五、关键总结

MoE 的完整因果链：

Dense FFN 只能通过增大同一 MLP 扩大参数
→ 每 Token 计算与参数一起增长

MoE 放置 E 个 Experts
→ Router 为每 Token 选择 k 个, $k \ll E$
→ 总参数由 E 决定，激活计算由 k 决定
→ 参数容量与每 Token 计算解耦

但动态路由产生不均匀 Token Assignment
→ 需要负载均衡与容量策略
→ Experts 分布到多 GPU 后需要两次 All-to-All
→ 形成通信、动态小 GEMM、显存和可观测性难题

分析任何 MoE 系统时固定问六个问题：

1. **Architecture**: 多少 Experts? Top-k? Expert 宽度? 是否 Shared Experts?

2. **Routing**: Softmax/Sigmoid? Aux Loss? Capacity? Dropless?
3. **Compute**: 每 Expert 收到多少 Token? Grouped GEMM 是否足够大?
4. **Communication**: EP 多大? All-to-All 是否跨节点? 暴露时间多少?
5. **Memory**: 全部 Expert 参数、梯度、优化器状态如何分布?
6. **Serving**: Prefill/Decode Batch 多大? 专家权重和通信能否摊薄?

可选自测

1. Shape 与容量题

B=4, S=2048, E=64, k=2, CapacityFactor=1.25

请计算:

- T;
- 总 Assignments;
- 每 Expert 平均 Assignments;
- Capacity C。

2. 参数与 FLOP 题

一个 Dense FFN 使用 $H=4096, F_{\text{dense}}=14336$; MoE 使用 $E=8, k=2$ 。如果希望主 Expert FLOP 近似 Dense FFN, 应如何估算 F_{expert} ? MoE 全部 Expert 参数约是 Dense FFN 的多少倍?

3. 工程决策题

某 MoE 训练中:

All-to-All = 35% Step Time
Grouped GEMM = 25%
Permutation = 15%
Max/Mean Expert Tokens = 2.8
Drop Rate = 4%

你会按什么顺序优化? 哪些优化是在减少通信量, 哪些是在减少暴露时间, 哪些是在改善负载与计算效率?

继续学习

1. 前置：MoE Router 与负载均衡损失 —— 深入 Top-k、Aux Loss、Z-Loss 和 Aux-Loss-Free Balancing。
2. 同层对比：Dense FFN、Switch、Mixtral、DeepSeekMoE —— 对比 Top-1/Top-2、Shared Experts 与细粒度专家。
3. 下游应用：Expert Parallel 与 DeepEP —— 深入 All-to-All Dispatcher、通信 Overlap 和跨节点拓扑。

回复 1、2 或 3 继续；也可以说“稍后”或“不感兴趣”。

事实来源与版本边界

本文的稳定原理基于 Sparsely-Gated MoE、GShard、Switch Transformer 与 DeepSeekMoE 的公开论文，以及截至 2026-07-29 的 NVIDIA Megatron Core MoE 官方文档。不同模型与框架在 Router Score、Top-k 归一化、Capacity、Token Drop、Aux Loss、Shared Expert、Dispatcher 和并行映射上存在差异；具体配置、函数名和性能应以目标版本源码与实测为准。